**МИНОБРНАУКИ РОССИИ**
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**
**Кафедра МО ЭВМ**

# ОТЧЕТ

**по научно-исследовательской работе**

**Тема: Разработка методики обнаружения аномалий в данных космических лучей**

Студент гр. 7303 _____ Пэтайчук Н.Г.

Руководитель _____ Мандрикова Б.С.

Санкт-Петербург

2022

**ЗАДАНИЕ**

**НА НАУЧНО-ИССЛЕДОВАТЕЛЬСКУЮ РАБОТУ**

Студент Пэтайчук Н.Г.

Группа 7303

Тема НИР: Разработка методики обнаружения аномалий в данных космических лучей

Задание на НИР:

Реализация и обучение нейронной сети для классификации данных нейтронного монитора на предмет наличия аномалий.

Сроки выполнения НИР: 01.09.2022 – 20.12.2022

Дата сдачи отчета: 18.12.2022

Дата защиты отчета: 27.12.2022

Студент _____ Пэтайчук Н.Г.

Руководитель _____ Мандрикова Б.С.

## АННОТАЦИЯ

В рамках данного семестра выполнен один из этапов научно-исследовательской работы, а именно реализация и обучение нейронных сетей, предназначенных для классификации данных нейтронного монитора. В отчете описаны основные шаги по уменьшению размерности матриц и обоснование этого, реализации и обучении модифицированной сети LeNet, а также рассмотрение сети AlexNet для решения задачи классификации данных нейтронных монитора. В конце отчета представлено описание предполагаемого решения, которое будет реализовано в рамках весеннего семестра.



## SUMMARY

During this semester, one of the stages of research work was completed, namely, the implementation and training of neural networks designed to classify neutron monitor data. The report describes the main steps to reduce the dimension of matrices and the rationale for this, the implementation and training of the modified LeNet network, as well as the consideration of the AlexNet network to solve the problem of classification of neutron monitor data. At the end of the report, a description of the proposed solution that will be implemented during the spring semester is presented.

**СОДЕРЖАНИЕ**

# ПОСТАНОВКА ЗАДАЧИ

Одним из основных объектов исследования астрофизики являются космические лучи (КЛ). Основными источниками космических лучей являются звёзды и происходящие в них реакции, однако основным объектом исследования природы космических лучей является Солнце как ближайшая к нам звезда и источник термоядерных реакций [2]. Различают как первичные космические лучи, то есть частицы, находящиеся в космическом пространстве, так и вторичные, являющиеся продуктом взаимодействия первичных КЛ с атмосферой Земли (в результате таких реакций порождаются широкие атмосферные ливни, которые можно наблюдать на расстоянии тысяч метров) [3].

Поток частиц, приходящих на Землю из космического пространства, непостоянен и зависит как от времени, так и от места наблюдения за космическими лучами [2]. Изменения потока космических лучей во времени и в пространстве называют вариациями космических лучей, и основную роль в их формировании играет Солнце. Различают периодические вариации, к которым относят 22-летние, 11-летние, 27-дневные и солнечно-суточные вариации, которые связаны с солнечной активностью и которые можно наблюдать и регистрировать с заданной периодичностью [3]. С другой стороны, существуют и непериодические вариации к ним относят эффект Форбуша и солнечные вспышки. Хоть вероятность их наступления и повышается с ростом активности Солнца, но точно предсказать их пока не удаётся, что в свою очередь является проблемой, так как космические лучи влияют на работу как человеческого организма (в особенности организма космонавтов), так и электронику: системы теле-, радио и спутниковой связи, системы GPS и ГЛОНАСС, электрические сети, нефтегазовые комплексы и т.д. Непредвиденные резкие изменения интенсивности космических частиц могут представлять из себя угрозу для жизни и здоровья людей, а также для функционирования электронной техники [1, 2]. Существующие методы прогнозирования интенсивности космических лучей и

предотвращения негативных последствий не являются достаточно эффективными, что определяет *актуальность* работы.

Одним из основных наземных приборов наблюдения за космическими лучами являются нейтронные мониторы [4], чей принцип работы основывается на генерации нейтронов приходящими нуклонами и ядрами в результате ядерной реакции и дальнейшем подсчёте образовавшихся нейтронов. Примеры данных, получаемых с нейтронных мониторов, показаны на рис. 1. Как можно заметить, полученные данные можно интерпретировать как функцию интенсивности космических лучей от времени, благодаря чему её можно анализировать на предмет выявления непериодических вариаций. Разработка такого метода определения непериодических вариаций и является основной задачей данной работы.

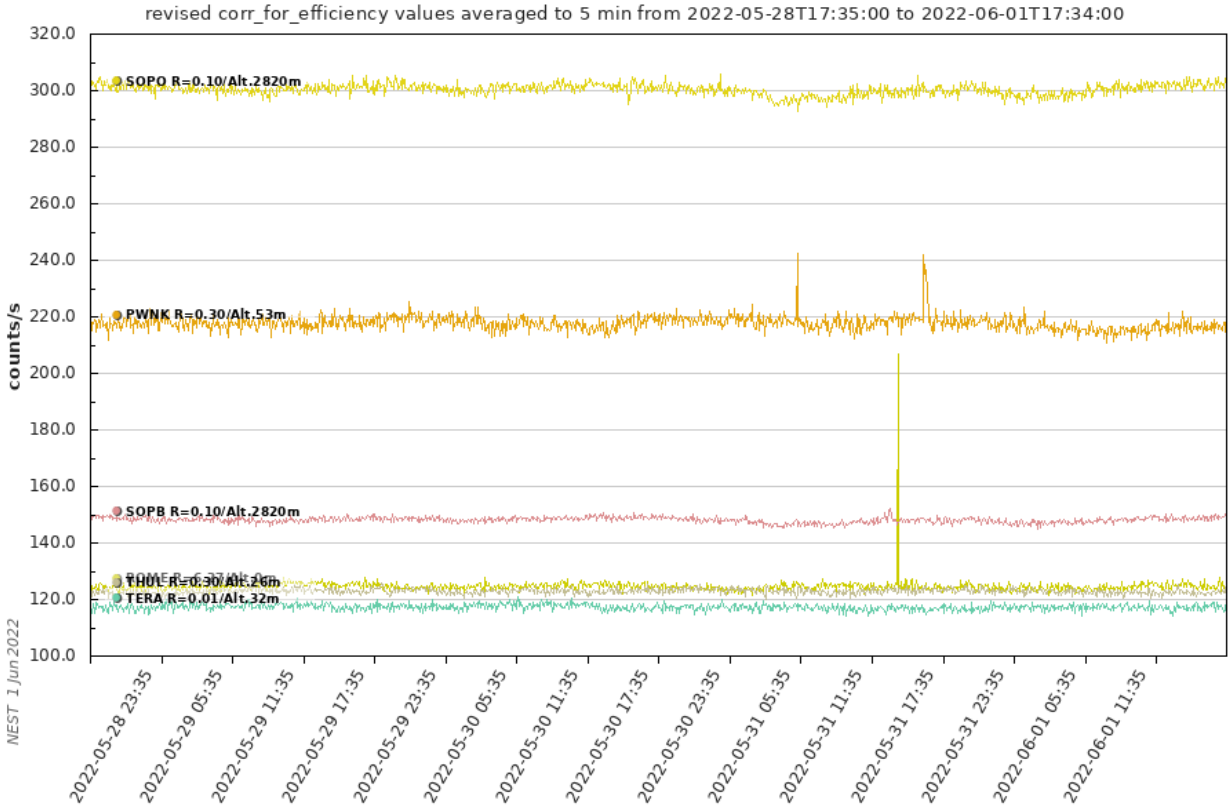


Рисунок 1 – Примеры данных, получаемых с нейтронных мониторов. По оси абсцисс подписаны временные метки, по оси ординат – число фиксируемых нейтронов в секунду. Цветами обозначаются нейтронные мониторы, с которых пришли данные

**Целью** данной работы является разработка методики обнаружения аномалий в сигнале космических лучей, по данным нейтронных мониторов.

**Задачи** данной работы:

1. Обзор существующих методов обработки данных с нейтронных мониторов;
2. Сравнительный анализ и выбор математических аппаратов, на основе которых будет разрабатываться метод идентификации непериодических вариаций;
3. Выбор инструментов и технологий для реализации метода идентификации непериодических вариаций;
4. Подготовка данных для настройки и проверки корректности работы метода идентификации непериодических вариаций;
5. Реализация метода идентификации непериодических вариаций;
6. Оценка эффективности полученной реализации метода идентификации непериодических вариаций.

# 1. РЕЗУЛЬТАТЫ РАБОТЫ В ОСЕННЕМ СЕМЕСТРЕ

В качестве планов на осенний семестр в отчёте по научно-исследовательской работе были представлены следующие задачи:

1. Обучение нейронной сети по сформированным данным при описанной архитектуре;
2. Анализ полученных в ходе обучения свёрточной нейронной сети результатов. В случае, если она показывает себя неудовлетворительно в плане точности классификации, выбор другой архитектуры и/или формирование иных исходных данных;
3. Планирование архитектуры и реализация приложения на базе обученной нейронной сети для идентификации аномалий в данных космических лучей.

Однако в ходе выполнения задачи 1 возникли проблемы, требующие выполнения действий, которые описаны в разделе 1.1, что также привело к изменению архитектуры нейронной сети, описанной в предыдущем отчёте по научно-исследовательской работе. С другой стороны, в ходе процесса обучения такой свёрточной нейронной сети не было получено удовлетворительной точности предсказания (70% и более), из-за чего была рассмотрена архитектура AlexNet для решения задачи классификации данных нейтронного монитора. Впрочем, и эта архитектура свёрточных нейронных сетей не смогла показать удовлетворительных показателей. Тем не менее, была разработана архитектура приложения, которая будет описана в разделе 1.4, однако реализовать её по вышеописанным причинам не удалось.

Блокноты (файлы формата .ipynb) с реализацией архитектур свёрточных нейронных сетей модифицированной LeNet и AlexNet https://github.com/NikitaPetaichuk/petaichuk_research_work в папке neural_networks.

### 1.1. Уменьшение размера матриц

Изначально предполагалось работать с матрицами размером 2327x1438, однако для обучения нейронной сети с помощью матриц такого размера требуются как хорошие вычислительные мощности (GPU или TPU), так и достаточное количество оперативной памяти для хранения матриц и промежуточных результатов вычисления. Поэтому возникла мысль о том, чтобы уменьшить размерность матриц, по которым будет обучаться нейронная сеть.

В то же время встаёт вопрос о том, не потеряется ли точность представляемых данных, ведь тут идёт речь о природных данных. Можно точно сказать, что уменьшение числа столбцов приведёт к уменьшению точности представления данных, так как число столбцов зависит от временного интервала замера количества нейтронов (каждую минуту, каждые две минуты и так далее), а, как было показано в предыдущем отчёте по научно-исследовательской работе, вейвлет-образы, полученные с 5-минутных данных, серьёзно отличаются о вейвлет-образов, полученных с ежеминутных данных. Единственной возможностью уменьшить размерность матриц без потери точности представления является уменьшение числа строк, то есть уменьшения масштаба рассматриваемых частот, за что отвечает 2 параметр в переменной scales в Matlab-скриптах do_wavelet.m и extract_data.m, которые находятся в вышеназванном Github-репозитории в папка processing_ extract_wavelet_data.

Были проведены эксперименты с помощью скрипта Matlab-скрипта do_wavelet.m по проверке того, отличаются ли вейвлет-образы, для которых число строк уменьшили в 10 раз при помощи изменения 2 параметра переменной scales с 1 на 10, от изначальных вейвлет-образов. Как видно из рис. 2 и рис. 3, принципиальных отличий в вейвлет-образах не наблюдается, а это значит, что вместо матриц 2327x1438 можно использовать матрицы 233x1440 (число столбцов было увеличено до 1440 для представления данных за полный день или 1440 минут). На основании вышесказанного, с помощью скрипта extract_data.m

был сформирован новый массив данных, в которых вместо матриц 2327x1438 используются матрицы 233x1440.

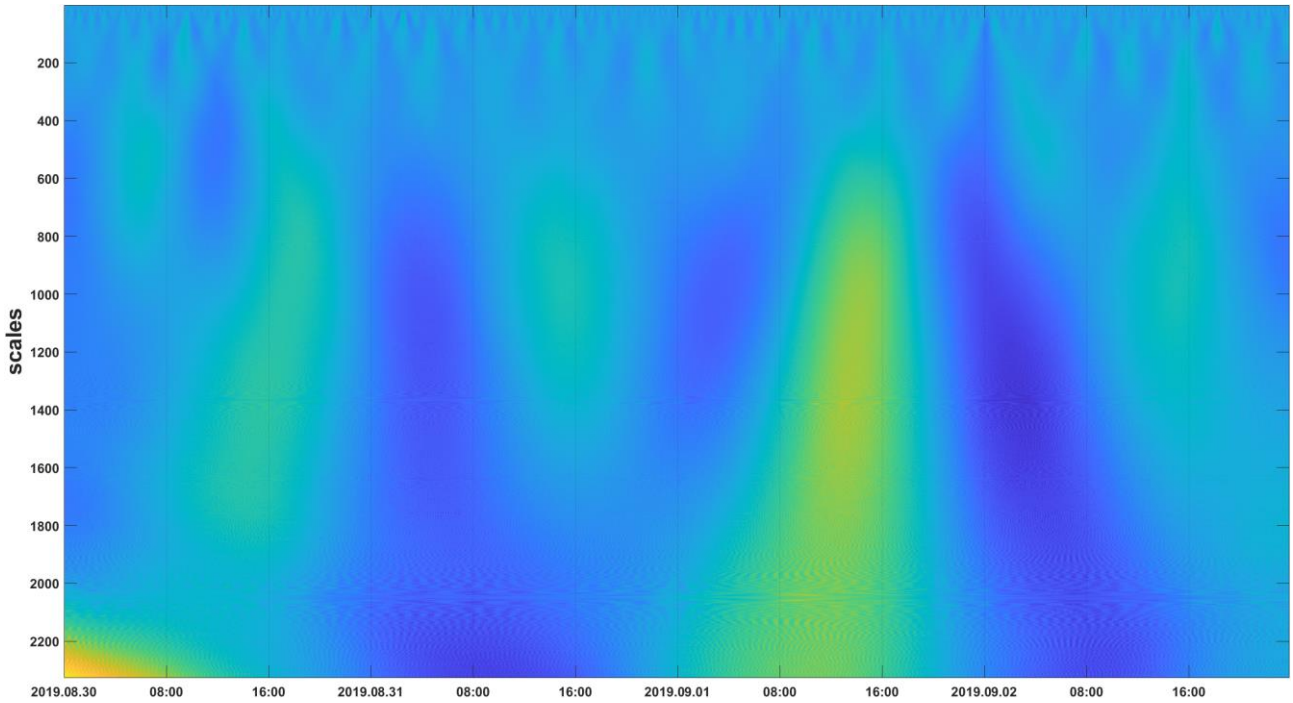


Рисунок 2 – Исходный вейвлет-образ, сформированный по данным за временной промежуток с 30.08.2019 по 02.09.2019 включительно

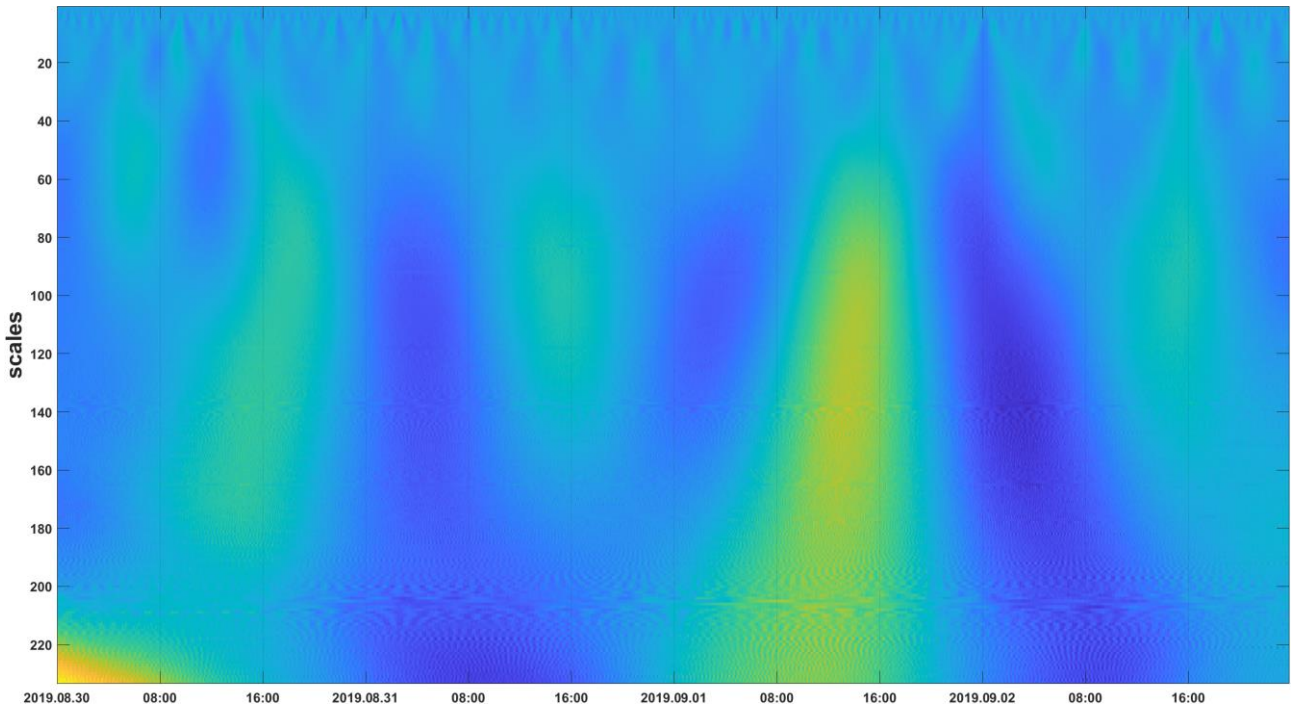


Рисунок 3 – Изменённый вейвлет-образ, сформированный по данным за временной промежуток с 30.08.2019 по 02.09.2019 включительно

Изменение размера матриц для обучения также требует корректировок для архитектуры нейронной сети, которая будет обучаться на новым данным. Были внесены следующие изменения в архитектуру:

- Входной слой – размер 233x1440,
- Ядро фильтра для свёртки – размер 36x36,
- После первой свёртки – 6 карт признаков размером каждая по 198x1405,
- После первой субдискретизации – 6 карт признаков размером каждая по 99x702,
- После второй свёртки – 16 карт признаков размером каждая по 64x667,
- После второй субдискретизации – 16 карт признаков размером каждая по 32x333,
- Два полносвязных слоя из 120 и 84 элементов (без изменений) и выходной слой из 3 элементов.

На рис. 4 представлена в графическом виде изменённая архитектура нейронной сети.

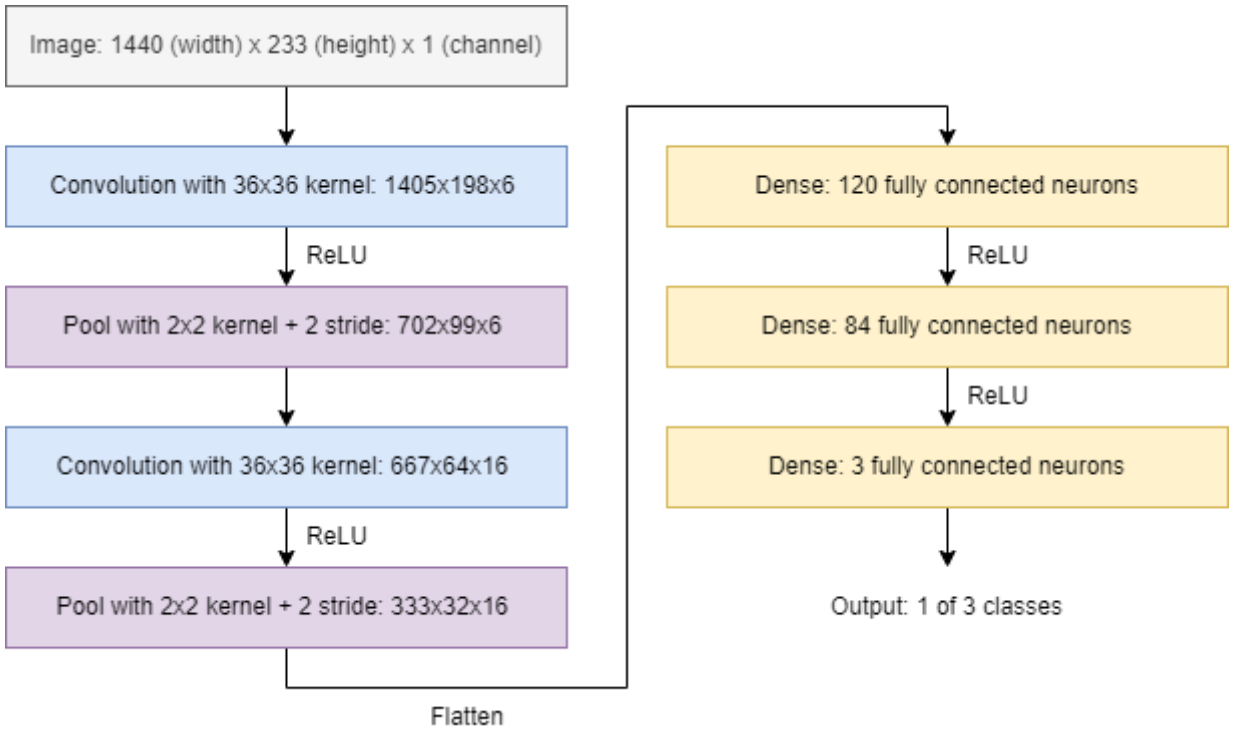


Рисунок 4 – Изменённая архитектура свёрточной нейронной сети

## 1.2. Реализация и обучение модифицированной сети LeNet для классификации данных нейтронных мониторов

Для реализации модифицированной архитектуры LeNet был выбран язык программирования Python и фреймворк PyTorch. Для обучения нейронной сети использовался веб-сервис Kaggle, где был создан датасет sopo_neutron_monitor_data на основе полученного ранее набора матриц, распределённых по папкам в зависимости от своего класса (спокойный день, слабая буря или сильная буря). Блокнот с модифицированной архитектурой LeNet представлен в Github-репозитории под именем neutron_monitor_data_lenet.ipynb в папке neural_networks.

Был реализован класс NeutronMonitorDataset, который реализует интерфейс стандартного класса Dataset фреймворка PyTorch по получению доступа к данным. В рамках класса NeutronMonitorDataset реализована «ленивая» загрузка данных, то есть при инициализации объекта класса формируется список путей к файлам с матрицами в датасете sopo_neutron_monitor_data и список соответствующих меток, а уже при попытке получения самой матрицы (вызов метода __getitem__) идёт загрузка матрицы по пути из списка, после чего возвращается преобразованная в тензор матрица (требуется для обучения) и метка этой матрицы. Исходный код класса NeutronMonitorDataset представлен на рис. 5.

Для итерации по данным в ходе обучения использовался стандартный класс DataLoader, в частности два объекта этого класса: для тренировочных данных и для валидационных данных. Объект класса NeutronMonitorDataset отвечает за доступ ко всем данным, поэтому для разделения данных на тренировочные и валидационные использовалась функция random_split. В итоге число матриц для обучения составило 85, число матриц для валидации – 10 (всего матриц 95).

```python
# Defining a class for neutron monitor dataset
class NeutronMonitorDataset(Dataset):
    def __init__(self):
        super().__init__()
        self._wavelets_files, self._labels = NeutronMonitorDataset._get_neutron_monitor_data_files()
        self._length = len(self._wavelets_files)

    @staticmethod
    def _get_neutron_monitor_data_files():
        wavelets_files, labels = [], []
        data_dirs_paths = [
            "../input/sopo-neutron-monitor-data/calm_days",
            "../input/sopo-neutron-monitor-data/weak_storms",
            "../input/sopo-neutron-monitor-data/strong_storms"
        ]
        for index, dir_path in enumerate(data_dirs_paths):
            wavelets_array, labels_array = NeutronMonitorDataset._get_data_files_from_directory(dir_path, index)
            wavelets_files.extend(wavelets_array)
            labels.extend(labels_array)
        return wavelets_files, labels

    @staticmethod
    def _get_data_files_from_directory(dir_path, label):
        wavelets_files_array = []
        for _, _, files in os.walk(dir_path):
            for file in files:
                if file != ".gitkeep":
                    file_path = os.path.join(dir_path, file)
                    wavelets_files_array.append(file_path)
        labels_array = [label for _ in range(len(wavelets_files_array))]
        return wavelets_files_array, labels_array

    def __len__(self):
        return self._length

    def __getitem__(self, index):
        sample_wavelet_file = self._wavelets_files[index]
        sample_wavelet_image = torch.tensor(
            np.loadtxt(sample_wavelet_file, dtype=np.float64, delimiter=','),
            dtype=torch.float32
        )
        sample_label = self._labels[index]
        return sample_wavelet_image, sample_label
```

Рисунок 5 – Исходный код класса NeutronMonitorDataset

Для реализации непосредственно модифицированной архитектуры был создан класс NeutronMonitorDataLeNet, содержащий два атрибута: один, feature_extractor, отвечает за все операции свёртки и пулинга (от англ. «pooling»), а второй, classifier, содержит все полносвязные слои нейтронной сети. Метод forward есть метод, который отвечает за применение нейронной сети к входным данным (так называемый «прямой ход»), то есть в данном случае он по полученной входной матрице вернёт вероятности принадлежности к конкретному классу. Исходный код класса NeutronMonitorDataLeNet представлен на рис. 6.

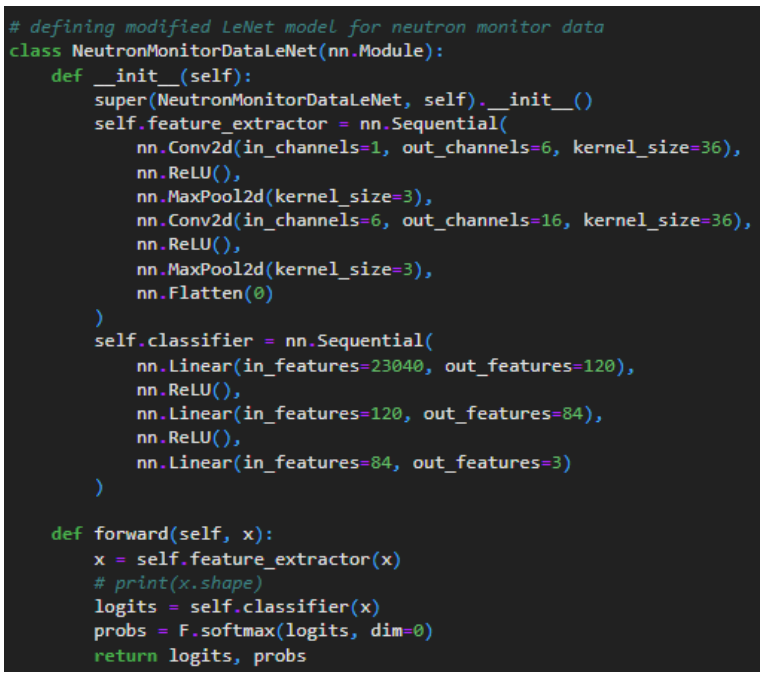

```
# defining modified LeNet model for neutron monitor data
class NeutronMonitorDataLeNet(nn.Module):
    def __init__(self):
        super(NeutronMonitorDataLeNet, self).__init__()
        self.feature_extractor = nn.Sequential(
            nn.Conv2d(in_channels=1, out_channels=6, kernel_size=36),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=3),
            nn.Conv2d(in_channels=6, out_channels=16, kernel_size=36),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=3),
            nn.Flatten(0)
        )
        self.classifier = nn.Sequential(
            nn.Linear(in_features=23040, out_features=120),
            nn.ReLU(),
            nn.Linear(in_features=120, out_features=84),
            nn.ReLU(),
            nn.Linear(in_features=84, out_features=3)
        )

    def forward(self, x):
        x = self.feature_extractor(x)
        # print(x.shape)
        logits = self.classifier(x)
        probs = F.softmax(logits, dim=0)
        return logits, probs
```

Рисунок 6 – Исходный код класса NeutronMonitorDataLeNet

Для обучения нейронной сети была создана функция training_loop, которая сначала проводит цикл обучения с помощью созданной функции train, потом проверяет степень обучения нейронной сети с помощью функции validate, после чего выводит информацию по эпохе (значение функции потерь и точность предсказания). Обучение происходило на GPU P100 16 GB, в качестве функции потерь использовалась кросс-энтропия, в качестве оптимизатора использовался метод адаптивной оценки моментов (или Adam).

К сожалению, модифицированная архитектура LeNet не смогла показать удовлетворительной точности предсказаний, остановивших на 40% при обучении и на 50% при валидации, как показано на рис. 7. При этом стоит отметить, что процесс обучения продолжается, что можно наблюдать по уменьшению значений функции потерь, однако уменьшается она крайне медленными темпами (на сотые, тысячные или десятитысячные доли). Предполагалось, что это может быть связано с недостаточной способностью архитектуры LeNet извлекать признаки, поэтому была дополнительно реализована и рассмотрена архитектура свёрточной нейронной сети AlexNet.

```
11:12:07 --- Epoch: 0   Train loss: 2.4468      Valid loss: 1.0666      Train accuracy: 35.29   Valid accuracy: 50.00
11:12:48 --- Epoch: 1   Train loss: 1.0924      Valid loss: 1.0481      Train accuracy: 35.29   Valid accuracy: 50.00
11:13:28 --- Epoch: 2   Train loss: 1.0887      Valid loss: 1.0319      Train accuracy: 35.29   Valid accuracy: 50.00
11:14:10 --- Epoch: 3   Train loss: 1.0860      Valid loss: 1.0186      Train accuracy: 40.00   Valid accuracy: 50.00
11:14:51 --- Epoch: 4   Train loss: 1.0843      Valid loss: 1.0084      Train accuracy: 40.00   Valid accuracy: 50.00
11:15:32 --- Epoch: 5   Train loss: 1.0832      Valid loss: 1.0008      Train accuracy: 40.00   Valid accuracy: 50.00
11:16:12 --- Epoch: 6   Train loss: 1.0826      Valid loss: 0.9956      Train accuracy: 40.00   Valid accuracy: 50.00
11:16:54 --- Epoch: 7   Train loss: 1.0822      Valid loss: 0.9919      Train accuracy: 40.00   Valid accuracy: 50.00
11:17:34 --- Epoch: 8   Train loss: 1.0820      Valid loss: 0.9896      Train accuracy: 40.00   Valid accuracy: 50.00
11:18:15 --- Epoch: 9   Train loss: 1.0819      Valid loss: 0.9881      Train accuracy: 40.00   Valid accuracy: 50.00
```

Рисунок 7 – Результаты обучения модифицированного LeNet после 10 эпох

### 1.3. Использование архитектуры AlexNet для классификации данных нейтронных мониторов

Архитектура AlexNet обладает большим числом операций свёрток и пулинга, как показано на рис. 8, а значит и способность извлекать признаки у такой архитектуры больше, нежели чем у LeNet. При этом саму архитектуру не требуется модифицировать, так как используемый изначально размер изображения 224x224 близок к числу строк у используемых для обучения матриц. Единственным отличием будет то, что в последнем полносвязном слое будет 3 нейрона вместо 1000.

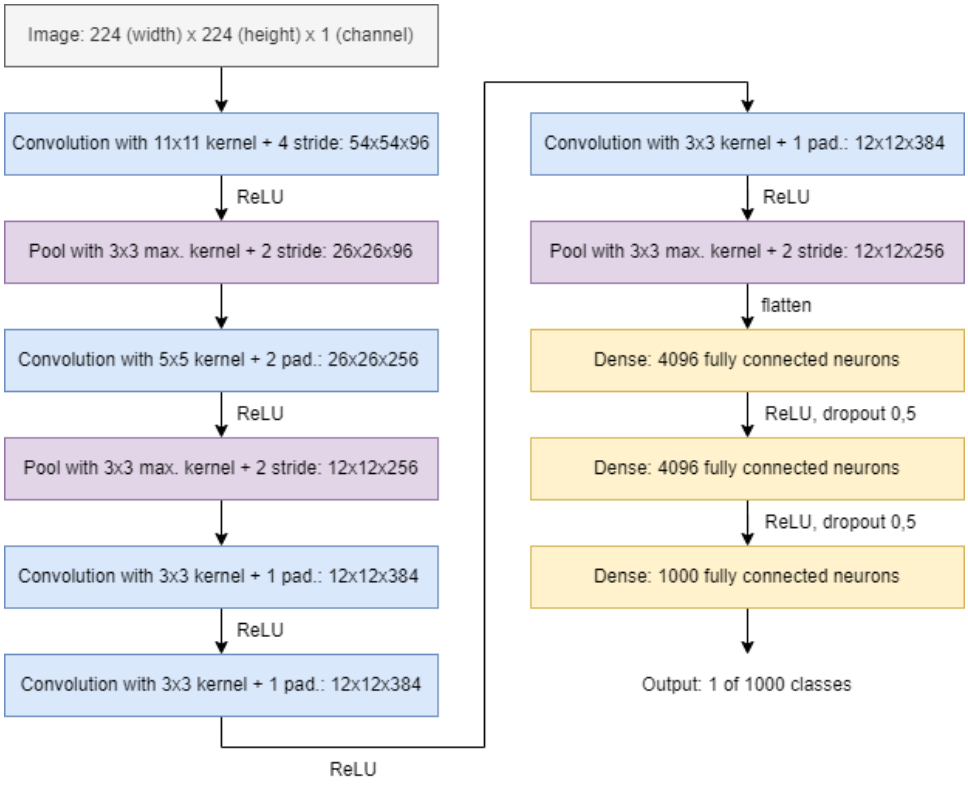


Рисунок 8 – Архитектура AlexNet

Для внедрения архитектуры AlexNet в существующий код необходимо лишь изменить класс NeutronMonitorDataLeNet, а точнее его атрибуты feature_extractor и classifier в соответствии с архитектурой AlexNet. Исходный код изменённого класса NeutronMonitorDataLeNet показан на рис. 9, весь код с предпринятыми изменениями был вынесен в отдельный блокнот neutron_monitor_data_alexnet.ipynb, который находится в папке neural_networks в Github-репозитории.

```
# defining modified LeNet model for neutron monitor data
class NeutronMonitorDataLeNet(nn.Module):
    def __init__(self):
        super(NeutronMonitorDataLeNet, self).__init__()
        self.feature_extractor = nn.Sequential(
            nn.Conv2d(in_channels=1, out_channels=64, kernel_size=11, stride=4, padding=2),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=3, stride=2),
            nn.Conv2d(in_channels=64, out_channels=192, kernel_size=5, padding=2),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=3, stride=2),
            nn.Conv2d(in_channels=192, out_channels=384, kernel_size=3, padding=1),
            nn.ReLU(),
            nn.Conv2d(in_channels=384, out_channels=256, kernel_size=3, padding=1),
            nn.ReLU(),
            nn.Conv2d(in_channels=256, out_channels=256, kernel_size=3, padding=1),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=3, stride=2),
            nn.Flatten(0)
        )
        self.classifier = nn.Sequential(
            nn.Dropout(p=0.5, inplace=False),
            nn.Linear(in_features=67584, out_features=4096),
            nn.ReLU(),
            nn.Dropout(p=0.5, inplace=False),
            nn.Linear(in_features=4096, out_features=4096),
            nn.ReLU(),
            nn.Linear(in_features=4096, out_features=3)
        )

    def forward(self, x):
        x = self.feature_extractor(x)
        logits = self.classifier(x)
        probs = F.softmax(logits, dim=0)
        return logits, probs
```

Рисунок 9 – Исходный код изменённого класса NeutronMonitorDataLeNet

Но, как было выяснено в ходе экспериментов, архитектура AlexNet показала себя не лучше, чем LeNet: точность предсказаний при обучении и при валидации осталась на том же уровне, как и значения функции потерь. Это показано на рис. 10.

```
12:36:04 --- Epoch: 0   Train loss: 4.4183      Valid loss: 1.0404      Train accuracy: 35.29   Valid accuracy: 50.00
12:36:45 --- Epoch: 1   Train loss: 1.1333      Valid loss: 0.9827      Train accuracy: 35.29   Valid accuracy: 50.00
12:37:26 --- Epoch: 2   Train loss: 1.0931      Valid loss: 1.0066      Train accuracy: 40.00   Valid accuracy: 50.00
12:38:08 --- Epoch: 3   Train loss: 1.0922      Valid loss: 0.9750      Train accuracy: 40.00   Valid accuracy: 50.00
12:38:49 --- Epoch: 4   Train loss: 1.0946      Valid loss: 1.0255      Train accuracy: 40.00   Valid accuracy: 50.00
12:39:29 --- Epoch: 5   Train loss: 1.0909      Valid loss: 1.0024      Train accuracy: 40.00   Valid accuracy: 50.00
12:40:11 --- Epoch: 6   Train loss: 1.0936      Valid loss: 1.0074      Train accuracy: 40.00   Valid accuracy: 50.00
12:40:52 --- Epoch: 7   Train loss: 1.0908      Valid loss: 1.0119      Train accuracy: 40.00   Valid accuracy: 50.00
12:41:32 --- Epoch: 8   Train loss: 1.0894      Valid loss: 1.0113      Train accuracy: 40.00   Valid accuracy: 50.00
12:42:14 --- Epoch: 9   Train loss: 1.0870      Valid loss: 1.0021      Train accuracy: 40.00   Valid accuracy: 50.00
```

Рисунок 10 – Результаты обучения AlexNet после 10 эпох

В связи с этим возникают следующие мысли по поводу поиска решения возникшей проблемы при обучении нейронной сети:

- Вероятно, в качестве архитектуры нужно использовать гораздо более продвинутые (например, ResNet) или специализированные архитектуры, предназначены для решения похожей задачи. Также качество обучения нейронной сети можно повысить за счёт применения специальных методик и техник, например, кросс-валидации;
- Также имеет смысл задуматься по поводу дополнительной предобработки исходных данных для избавления от потенциальных шумов, которые присущи природным данным и которые могут мешать процессу обучения.

После решения проблемы с обучением нейронной сети для классификации данных, полученных с нейтронного монитора, можно будет уже приступать к реализации приложения, основывающегося на этой нейронной сети.

### 1.4. Описание предполагаемого метода решения

Предполагаемое решение будет в формате десктопного приложения. Поскольку главной его составляющей будет нейронная сеть, реализованная на языке программирования Python с применением фреймворка PyTorch, то и реализовывать всё приложение имеет смысл с использованием библиотеки PyQt, что в свою очередь обеспечит его кроссплатформенность. Приложение при запуске будет подгружать хранящие в отдельном файле параметры нейронной сети, полученные после её успешного обучения. Помимо этого, на язык программирования Python в целях внедрения в приложение будет переписаны операции по вейвлет-преобразованию, которые на текущий момент представлены в формате Matlab-скриптов. Предполагается, что для этих целей будет использоваться библиотека PyWavelets. Также на языке Python будут реализованы дополнительные операции по предобработке данных, если они потребуются.

Макет предполагаемого решения представлен на рис. 11. Типичный сценарий использования приложения заключается в следующем:

1. Выбор файла для анализа:
    a. Пользователь вводит в поле ввода путь до файла в формате <временная_метка>;<число_зафиксированных_нейтронов>, в котором хранятся данные, полученные с нейтронного монитора за конкретный день;
    b. Либо пользователь может нажать кнопку «Обзор», чтобы в появившемся окне выбрать нужный файл;
2. Пользователь нажимает на кнопку «Обнаружить аномалию», после чего ожидает обработки данных из файла, которая заканчивается выведением результата о наличии бурь в дань, данные по которому были проанализированы, плюс выведением вейвлет-образа, сформированного по полученным данным;
3. Пользователь может при желании сохранить полученный вейвлет-образ путём нажатия на кнопку «Сохранить вейвлет-образ» и последующим вводом имени файла и выбором местоположения в открывшемся окне.

Обработка данных при нажатии кнопки «Обнаружить аномалию» будет заключаться в выполнении следующих шагов:

1. Чтение данных из файла, проверка их на корректность формата;
2. Выполнение вейвлет-преобразования считанных данных, получение вейвлет-образа в форме матрицы;
3. Дополнительная предобработка полученной матрицы, если она требуется;
4. Применение матрицы в качестве входных данных для нейронной сети;
5. На основе набольшей из полученных вероятностей принадлежности к конкретному классу вывести на экран сообщение о наличии бурь («Спокойный день, никаких космических бурь», «Неспокойный день, слабые бури» или «Неспокойный день, сильные бури»), а также вывести на экран вейвлет-образ.

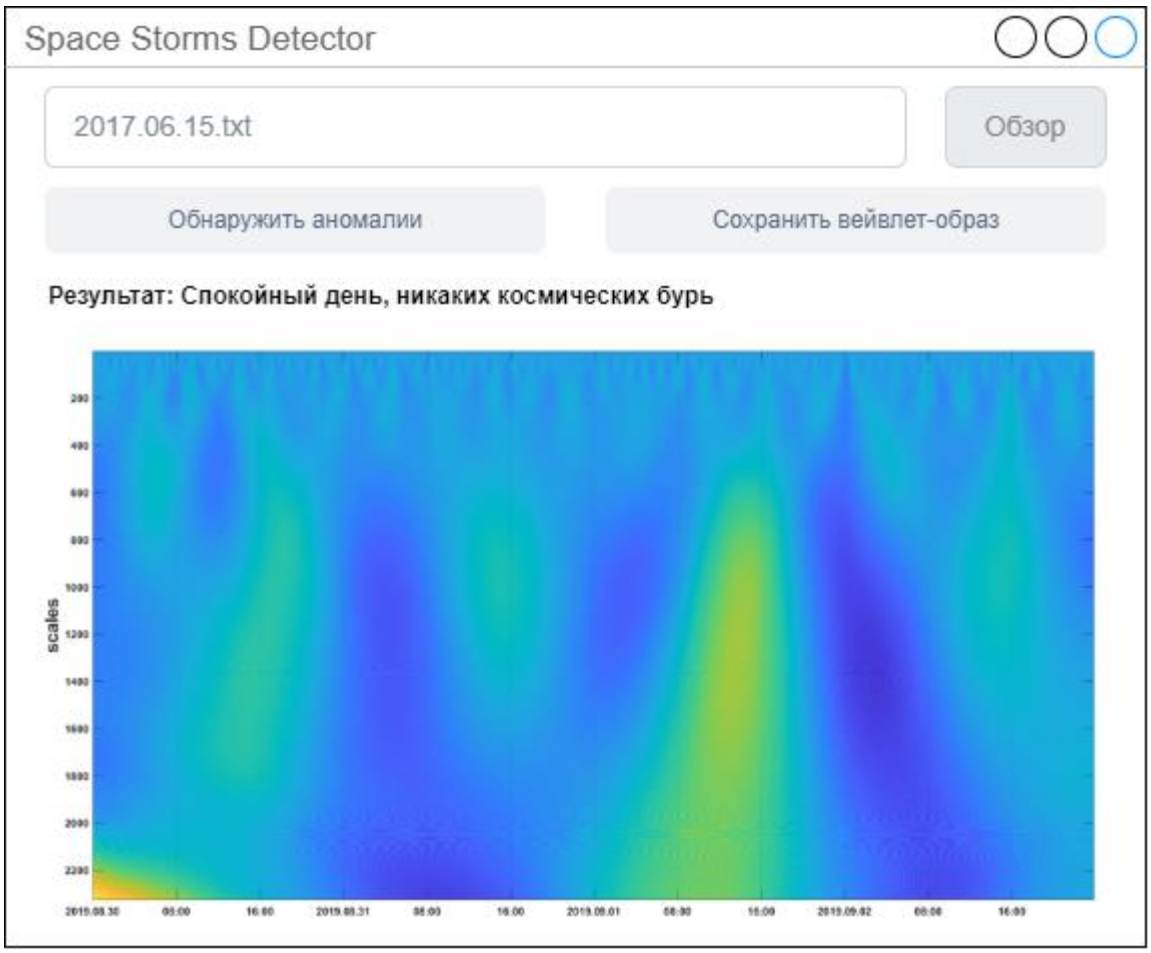


Рисунок 11 – Макет предполагаемого решения

# 2. ПЛАН РАБОТЫ НА ВЕСЕННИЙ СЕМЕСТР

По результатам выполнения задач за осенний семестр был построен план работы на весенний семестр, который включает в себя следующие задачи:

1. Рассмотреть другие пути решения возникшей проблемы с обучением свёрточной нейронной сети для классификации данных, полученных с нейтронного монитора (продвинутые/специализированные архитектуры, дополнительные этапы предобработки данных), с целью достижения необходимого уровня точности предсказаний;
2. На основе макета и параметров обученной нейронной сети реализовать решение в виде декстопного приложения;
3. Проанализировать параметры работы полученного решения на предмет скорости работы и других характеристик.

# ЗАКЛЮЧЕНИЕ

В ходе работы за осенний семестр были рассмотрены модифицированная архитектура LeNet и архитектура Alex в целях их использования для решения задачи классификации данных, полученных с нейтронного монитора. Была рассмотрена возможность уменьшения размера матриц для их использования в целях обучения нейронной сети, а также были предприняты попытки обучения нейронных сетей с вышеобозначенными архитектурами. Хоть никакой из архитектур и не удалось добиться требуемой точности предсказания, но были предложены возможные пути решения этой проблемы, а также было представлено описание предполагаемого, базирующегося на нейронной сети, предназначенной для классификации данных, полученных с нейтронного монитора.

# СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Мирошниченко Л. И. Физика Солнца и солнечно-земных связей: учебное пособие // Л. И. Мирошниченко; Под ред. М. И. Панасюка. — М.: Университетская книга, 2011, 345 с.

2. Мурзин В.С. Астрофизика космических лучей: Учебное пособие для. вузов. — М.: Университетская книга; Логос, 2007, 488 с.

3. Топтыгин И.Н. Космические лучи в межпланетных магнитных полях. — М.: Наука, 1983, 304 с.

4. Real time data base for the measurements of high-resolution Neutron Monitor. [Электронный ресурс]. www.nmdb.eu (дата обращения 15.03.2022).